

시대가 AI를 던져줄 때, 사회학의 방법론으로 활용하기

발표: 김란우 (KAIST 디지털인문사회과학부, lanukim@kaist.ac.kr)

도움: Maida Aizaz (KAIST GSDS), 천지향 (KAIST GSDS)

2026 한국사회학회 신진학자 심포지엄

Computational Sociology Lab (<https://computationalsociologylab.github.io>)

Lanu Kim personal webpage (<https://lanukim.github.io>)



오늘 이야기 할 것

- ✓ AI/LLM의 사회과학 방법론 활용 — 세 가지 층위 소개 및 설명
- ✓ 각 층위의 구체적인 연구과정 및 연구 사례 소개
- ✓ 검증 방법론 (내적·외적 타당성)
- ✓ 앞으로 나아갈 방향성 및 사회학자에게 남겨진 질문 제안



오늘 이야기 하지 않을 것

- X LLM 기술 자체의 작동 원리
- X 프로그래밍 / API 코딩 튜토리얼
- X AI 윤리의 철학적 논의
- X 모든 활용 사례의 포괄적 서베이 (논문 검색 및 요약, 영어 교정, 작문, 코딩 프롬프트 등)



사회(과)학 연구에서 AI 활용의 세 가지 층위

AI의 연구 침투 정도
낮음

높음

비개입적 활용 (Non-intrusive use)

- 인간 연구자의 노동이 수월해지도록 보조
- AI 이전과 동일한 연구 디자인 유지
- 인간 노동력의 단순 대체

예) LLM이 실험에 쓰이는 자극물 생성

확장적 활용 (Augmentative use)

- 인간이 할 수 있었지만 규모상 불가능한 작업을 실현시킴.
- AI 이전보다 연구대상을 양적으로 확장한 연구 디자인 적용 가능
- 인간 노동력의 증강

예) 수백만건의 텍스트를 같은 기준으로 코딩함.

침투적 활용 (Immersive use)

- 인간이 할 수 없었던 새로운 방식의 작업 가능성을 제시함.
- AI 이전과 질적으로 다른 연구 디자인을 개발하고 고민할 필요
- 인간 노동력에서 창의력으로의 전환

예) 합성 데이터, 사회 시뮬레이션

발표 순서

1 AI의 비개입적 활용 소개

2 AI의 확장적 활용 소개

3 AI의 침투적 활용 소개

4 종합
세 층위의 비교와 미래 방향



발표 순서

1 AI의 비개입적 활용 소개

2 AI의 확장적 활용 소개

3 AI의 침투적 활용 소개

4 종합 세 층위의 비교와 미래 방향

비개입적 활용(Non-intrusive use)

- AI로 실험 자극물을 생성하거나 파일럿 테스트 대상으로 활용하되, 인간 연구자가 설계를 통제
- AI를 도구로 활용하여 인간의 노동력을 대체하되, 연구 과정은 이전과 동일하게 유지
- 전반적으로 기존 연구의 틀을 유지하되 질을 높일 수 있음.

활용 사례

실험용 가짜 자극물 생성

- 인종·성별 신호를 조작한 실험용 이력서 혹은 사진을 AI로 대량 생성
- 가짜뉴스를 포함한 신문 기사 생성

Choi and Kim (2026)

Topic model의 레이블 달기

- Unsupervised topic model의 경우, 주제별 이름을 제시하지 않음.
- GPT에게 주요 단어를 주고 레이블을 붙이게 함.

Aizaz et al. (2025)

설문 문항 파일럿

- AI로 문항 변형을 대량 생성하여 사전 테스트 효율화

비개입적 활용 사례

- 기업은 위기 상황에서 직원들에게 어떻게 메시지를 보내는게 가장 효과적일까?
 - 다양한 기업의 위기 상황: 사고(생산 설비 사고로 인한 인명 피해), 산업 불황(반도체 시장 수요 급감), 경쟁력 저하(반도체 기술력 저하), 자연재해(태풍), 규칙 위반(법률 위반)
 - 메시지를 구성하는 요소
 - 문제 관련 투명성 (원인을 밝힘 / 밝히지 않음)
 - 조직 대응 방안 (숫자 기반 플랜 / 전체적인 방향성 공유 / 극복 의지 강조 / 성과에 대한 보상)
 - 위로-공감 여부 (위로-공감 있음 / 위로-공감 없음)
- 위기 상황마다 서로 다른 메시지를 생성하여 실험 참여자들에게 메시지를 Pair로 제시하며 선호 여부를 테스트하는 Conjoint analysis를 실시함.
 - 서로 다른 메시지의 수: 위기상황 5건 * 투명성 여부 2 종류 * 조직 대응방안 4 종류 * 위로-공감 여부 2종류 = 80개의 메시지가 필요
 - 일관성 있는 80개의 메시지 생성이 어려움.
 - GPT를 활용하여 초안을 만들고, 인간이 수정함.



사고 (생산설비 사고로 인한 인명 피해)		
문제 관련 투명성	원인을 밝히지 않음 (A.1)	지난 5월 25일, 당사의 반도체 생산라인에서 작업 중 중대한 안전사고가 발생했습니다. 이로 인해 작업자 한 명이 심각한 부상을 입었습니다. 현재 정확한 원인 분석과 재발 방지 대책 수립을 위하여 모든 상황을 신속히 파악하고 있으며, 필요한 조사 절차를 진행 중에 있습니다. 당사는 직원의 안전을 최우선으로 하여 철저한 검토를 실시하고 있습니다.
	원인을 밝힘 (A.2)	지난 5월 25일, 당사의 반도체 생산라인 내 고온 공정 설비에서 작업 중이던 직원이 장비 이상 반응에 노출되어 중상을 입은 사고가 발생했습니다. 장비 작동 신호와 실제 반응 간 시간 차가 있었던 것으로 파악됩니다. 해당 설비는 전면 중단 조치되었으며 정확한 원인 분석 및 재발 방지 대책 수립을 위한 조사가 진행 중입니다.
조직 대응 방안	숫자 기반의 구체적인 액션 플랜 (B.1)	회사는 다음과 같은 구체적인 개선 방안을 즉시 시행합니다. 첫째, 사고 설비 라인은 즉시 가동 중단 후 30일 이내 전 사업장 안전 점검을 완료하겠습니다. 둘째, 1년 이내 총 15억원을 투자하여 노후 설비 교체 및 안전장치 보강을 진행하겠습니다. 셋째, 60일 이내 전 직원 대상 6시간 의무 안전교육을 실시하며, 위험 작업 담당자는 추가로 8시간의 고위험 공정 대응 교육을 의무화하겠습니다.
	전체적인 방향성 공유 (B.2)	회사는 이번 사고를 계기로 안전 관리 체계를 전면 개편하겠습니다. '작업자 안전 최우선' 원칙을 모든 운영 기준의 최상위에 두고, 안전 관리를 단순한 규정 준수를 넘어 조직 문화로 정착시킬 것입니다. 현장 중심의 안전 관리를 강화하여 실질적인 위험 요소를 사전에 발견하고 제거하는 데 주력하겠습니다. 고위험 공정에 대한 설계, 관리, 인력 배치까지 전 과정을 전면 재검토하겠습니다.
	극복 의지 강조 (B.3)	이번 사고를 통해 우리는 안전이 그 어떤 가치보다 우선되어야 함을 다시 한번 절실히 깨닫게 되었습니다. 이 아픔을 우리 모두의 교훈으로 삼아, 더 안전한 일터를 만들어가는 계기로 삼고자 합니다. 우리는 이 위기를 반드시 극복하고, 안전한 기업문화를 정착시켜 나갈 것입니다. 지금은 모든 임직원이 한마음으로 이 어려움을 이겨내는 자세가 무엇보다 중요합니다.
	성과에 대한 보상 제공 (B.4)	회사는 안전 개선에 기여한 제안자와 실무 실행자에게 분기별 인센티브를 지급하고자
메시지 톤		합니다. 사고 예방 우수 직원에게는 최대 500만원의 보상을, 우수 팀에는 최대 1,000만원의 보상과 특별 휴가를 제공합니다. 안전 혁신 아이디어 제안자에게는 최대 300만원의 별도 포상을 지급하고, 무사고 부서에는 분기별 팀 인센티브 200만원을 지급하여 안전 문화 정착을 적극 지원하겠습니다.
	위로/공감 있음 (C.1)	이번 사고로 인해 많은 분들이 충격과 슬픔에 빠졌을 것입니다. 회사는 사고 피해자와 가족, 그리고 현장 구성원들의 고통을 깊이 공감하며, 다시는 이런 일이 반복되지 않도록 모든 조치를 다하겠습니다.
	위로/공감 없음 (C.2)	이번 사고는 중대한 시스템적 문제로 간주되며, 이에 따라 전사 차원의 강도 높은 점검 및 개혁 조치가 즉시 시행됩니다. 각 부서는 재점검 항목을 빠짐없이 이행하고, 향후 모든 사고 책임은 관리 주체에게 부과될 예정입니다.

산업 불황 (반도체 시장 수요 급감으로 인한 위기)		
문제 관련 투명성	원인을 밝히지 않음 (D.1)	최근 반도체 시장 전반의 수요 감소로 인해 당사 역시 큰 영향을 받고 있습니다. 이번 수요 하락의 구체적인 원인에 대해서 회사는 현재의 상황을 예의주시하며, 내외부 환경 분석을 지속하고 있습니다. 급변하는 시장 흐름 속에서 대응 방안을 다각도로 모색하고 있으며, 장기적 관점에서 시장 회복에 대비한 전략적 준비를 강화하고 있습니다.
	원인을 밝힘 (D.2)	최근 글로벌 반도체 수요가 전반적으로 감소하고 있으며, 당사의 주요 고객사 주문량도 큰 폭으로 줄어들어 당사의 반도체 출하량이 전년 대비 20% 감소하는 등 타격을 받고 있습니다. 이는 글로벌 경기 둔화, 인플레이션 등 여러 외부 요인이 복합적으로 작용한 결과로 파악되고 있습니다. 회사는 시장 상황을 면밀히 분석하고, 전사적 대응 전략을 수립 중입니다.
조직 대응 방안	숫자 기반의 구체적인 액션 플랜 (E.1)	회사는 향후 6개월간 생산량을 30% 감축하고, 원가 절감을 위한 주요 고정비를 20% 이상 축소할 예정입니다. 동시에 고부가가치 제품 비중을 기존 35%에서 50%로 확대하고, 신규 고객 10개사 유치를 목표로 한 영업 강화를 추진하겠습니다.
	전체적인 방향성 공유 (E.2)	회사는 제품 포트폴리오 다변화와 시장 구조 변화 대응을 핵심 전략으로 설정하고
메시지 톤		있습니다. 범용 메모리 중심 구조에서 벗어나 AI, 차량용 반도체 등 전략 품목 확대를 추진하며, 전사 차원의 생산 최적화 및 수익성 중심 운영체제로 전환하겠습니다.
	극복 의지 강조 (E.3)	당사는 과거 수많은 위기를 극복한 경험을 바탕으로, 이번 산업 불황 또한 도약의 기회로 삼을 것입니다. 우리는 더욱 민첩하고 탄력적인 조직으로 변화하고 있으며, 모든 임직원의 힘을 모아 반드시 이 위기를 극복하고 더 강한 회사로 거듭나겠습니다.
	성과에 대한 보상 제공 (E.4)	회사는 위기 극복에 기여한 팀과 개인에게 분기별 특별 인센티브를 지급하고, 비용 절감 및 공정 혁신 사례를 발굴하여 정기 포상을 실시하겠습니다. 고성과 팀에게는 팀 단위 포상휴가와 별도 격려금을 지급할 계획입니다.
	위로/공감 있음 (F.1)	임직원 여러분, 현재의 불확실성과 위기 속에서 많은 걱정과 피로를 느끼고 계실 것입니다. 회사는 여러분의 헌신과 노력에 깊이 감사드리며, 함께 이 어려움을 극복할 수 있도록 적극적으로 지원하겠습니다.
	위로/공감 없음 (F.2)	현재의 산업 불황 상황은 전사적 전환이 필요한 구조적 도전입니다. 회사는 모든 전략을 재정비하며, 각 부서별로 정해진 목표와 지표를 엄격히 준수해 주시기 바랍니다. 모든 구성원이 명확한 역할을 수행해야 합니다.





비개입적 활용의 소결

장점

- 대규모 실험 재료를 빠르고 저비용으로 생성
- 완벽한 조작 통제 가능
- 인간 연구보조원의 주관적 편차 제거

한계

- 프롬프트 민감성: 작은 문구 변화가 다른 결과 초래
- 생태적 타당성 의문
- 원하는 자극물을 정확히 생성하기 어려울 가능성

방법론적 위치

- 인간이 여전히 연구의 주체
- AI는 실험 도구를 만드는 보조 수단
- 기존 방법론의 효율화

비개입적 활용 = 가장 안전한 활용법이나 AI 생성물의 편향 검증은 필수임.

발표 순서

1 AI의 비개입적 활용 소개

2 AI의 확장적 활용 소개

3 AI의 침투적 활용 소개

4 **종합**
세 층위의 비교와 미래 방향

확장적 활용(Augmentative use)

- 인간과 AI가 협업하여, AI 이전보다 연구대상을 양적으로 확장(scale)한 연구 디자인 적용 가능
- 인간이 코드북을 설계하고, 코딩 정답지(ground truth)를 만들면, LLM이 대규모 텍스트 데이터에 주석을 담.
- 시간과 비용의 제약을 넘어, 이전에는 불가능했던 규모의 텍스트 분석 가능
- **인간이 설계한 틀 안에서 AI가 규모를 확장 => 인간 생산성 증강**
- **확장적 활용의 원칙: 인간의 판단이 시작점이자 종착점**

활용 사례

Stack Overflow 질문 난이도 측정

- Stack Overflow에 올라온 약 5만건 질문들의 난이도를 쉬움/중간/어려움으로 나누어 측정

Han et al. (2026)

합성 데이터 보강

- 팩트체크 데이터셋의 클래스 불균형 해결 — 소수 클래스 성능 향상

Moe et al. (2025)

사회학 논문의 기여 종류 측정

- 사회학 논문 초록을 통해 연구의 주된 기여가 이론적 기여인지 경험적 기여인지 분석함.

Kwon et al. (2026)

확장적 활용의 과정: 인간의 판단이 시작점이자 종착점

1

인간이 설계

- 코드북 설계
- 표본 선정
- 연구 질문 정의

Ground Truth 코딩 방법

- 전문가 코딩 (연구자 직접)
- 코딩 매뉴얼 작성
- (전문가 수는 홀수 선호)
- Inter-coder reliability 확인
- 학습용(train set) / 검증용(validation set) 비율은 80:20 / 90:10
- 학습/검증용 데이터는 섞이면 안됨.

2

AI가 확장

- 대규모 텍스트 코딩
- 클래스 불균형 보강
- 다국어 처리

프롬프팅 전략 선택

- 학습용 데이터를 예시 혹은 재학습 데이터로 사용
- Zero-shot (예시 없이 prompt)
- Few-shot (종류별 3-4개 예시를 주고 prompt)
- Fine-tuning (모델 재학습)
- ± Chain-of-Thought

3

인간이 검증

내적 타당성(LLM 일관성)
및 외적 타당성(정답지와 비교) 검증

검증 지표 제시

- 내적타당성: 반복 일관성, 모델 간 일치
- 검증용 데이터를 사용하여 외적타당성 검증: F1 score, accuracy, precision, recall

프롬프팅 전략의 비교

Zero-shot

예시 없이 지시만으로 수행

장점

- 빠르고 저비용
- 설정 간단
- 새 과제 즉시 적용

한계

- 복잡한 과제에 부정확
- 코드북 해석 편차

정확도: 보통

비용: 낮음

Few-shot

종류별 3-4개 예시를 주고 지시

장점

- 정확도 향상
- 코드북 맥락 전달
- 비용 대비 효과적

한계

- 예시 선택에 민감
- 토큰 비용 증가

정확도: 높음

비용: 중간

Fine-tuning

데이터로 모델 재학습

장점

- 최고 정확도
- 과제 특화 성능
- 일관성 높음

한계


- 학습 데이터 필요
- 높은 비용
- 재현성 이슈

정확도: 최고

비용: 높음

± Chain-of-Thought (CoT): 모든 전략에 추가 가능. LLM이 단계별 추론을 거치도록 유도 → 복잡한 과제에 효과적이나 토큰 비용 증가 (Wei et al. 2022)

Fig.6 in Chae and Davidson (2025)



검증: 내적 타당성(Internal validity)

AI 응답의 일관성 측정

Intra-model Consistency

같은 LLM 내 반복 일관성

- Temperature를 낮게 설정 (0~0.3)
(0은 결정론적이나 분포 정보 상실)
- 동일 프롬프트로 N회 반복 실행
- 응답 간 일치율 측정

측정: 반복 재현율, 응답 분산, 최소 2회 실행 권장

Inter-model Agreement

서로 다른 LLM 간 일치도

- OpenAI GPT, Llama, Claude 등 교차 검증
- 모델 간 합의 = 과제의 명확성
- 모델 간 불일치 = 해석의 여지

내적 타당성이 확보되지 않으면 외적 타당성 검증은 무의미

검증: 외적 타당성(External validity)

인간 주석(Ground truth)과의 비교

	실제: Positive	실제: Negative
예측: Positive	TP (True Positive)	FP (False Positive)
예측: Negative	FN (False Negative)	TN (True Negative)

Accuracy = $(TP+TN) / (TP+TN+FP+FN)$

→ 전체 중 맞은 비율

Precision = $TP / (TP+FP)$

→ Positive 예측 중 실제 Positive 비율

Recall = $TP / (TP+FN)$

→ 실제 Positive 중 탐지한 비율

F1 = $2 \times (Precision \times Recall) / (Precision + Recall)$

F1이 주요 지표 — 클래스 불균형 상황에서 Accuracy만으로는 부족

확장적 활용(Augmentative use)의 사례 (1)

Do easy questions in Stack Overflow decrease faster after ChatGPT than *difficult questions*?

- Analytic challenge: **measuring difficulty of questions**

Data Extraction

2008.07

2021.11

2023.12



Question data

2 years

Han et al. (2026)

What is a difficult question?



Difficulty level	General rule set	Granular breakdown	(Raida et al., 2024)
Basic	Questions on simple built-in functions/API documentation/beginner level knowledge	Regular Built-in-function	
Basic	Questions related to comparison between concepts and functions of various languages	Analysis of various languages' functions	
Basic	Questions about simple problem-solving or random topic	Simple problem solving	
Basic	Questions with simple exception, error, and other problem	Solve for null reference issue	
Intermediate	Questions that require a relatively deeper understanding of the language to answer, for example Why type questions	Advanced features of a language that require deeper understanding	
Intermediate	Questions where the questioner knows about the answer/solution but wants to know a more efficient one	Looking for contextually suitable solution despite having a solution	
Intermediate	Questions related to time complexity, memory usage or other different resource usages of a system/solution	Efficient way	
Intermediate	Questions need conceptual reasoning of programming construct/design principle	Reverse programming	
Advanced	Questions that deal with hard/critical problems where solution needs in-depth programming knowledge or conceptual/logical thinking	Solution needs in-depth programming knowledge or conceptual thinking	
Advanced	Questions that require advanced in-depth knowledge of internal language structure	In-depth knowledge of internal language structure	
Advanced	Questions that deal with infrequently used functions	Deals with infrequently/rarely used framework/API/functions	
Advanced	Question that requires in-depth knowledge about software architecture & SDLC	In-depth knowledge of software architecture	
Advanced	Related to production environment	Efficiency related question	
Advanced	Question that deals with rare and diversified topics	Need in-depth knowledge of multiple topics	

Han et al. (2026)



How to calculate the total of each list, in a list of lists Python

Basic Level

asked 5 years, 6 months ago Modified yesterday Viewed 2k times



0

I have collected a list of lists, each list representing data from a single day. I need to find the SUM of these to calculate the total volume each day. I can only seem to add together each list, not an individual lists data.



Provides the total of all the lists, not each individual lists total.



```
for ele in range(0, len(y_pred)):
    total = total + y_pred[ele]

print (total)
```

Expected 18 outputs, each lists sum, not one output with a sum of everything.

Han et al. (2026)

Expired tokens are not deleted after expiration in django-rest-knox 4.1.0

Asked 2 years ago Viewed 227 times

Advanced Level

I'm using django-rest-knox 4.1.0 . In its documentation it says that expired tokens are deleted automatically. But it is not deleting the tokens.

1

```
REST_FRAMEWORK = {  
    "DEFAULT_AUTHENTICATION_CLASSES": (  
        "knox.auth.TokenAuthentication",  
    ),  
}
```

Too time consuming and not scalable.


In settings.py I gave 10 minutes for expiration of token (for testing purposes). ["TOKEN_TTL": timedelta\(minutes=10\)](#).

I check the database after that time, they are not deleted. [pgadmin knox token table](#) Also I try to send request with those expired tokens, the respond is successful.

python django django-rest-framework token django-rest-knox

Han et al. (2026)

Difficulty Measure



How to Measure Difficulty of Questions

3. LLM Tuning

Apply in-context learning
Implicit Chain of Thought(CoT)
Self-Consistency



Iterate the process and check accuracy




draw Q
for evaluation



draw Q
for few shot

few shot			CoT			Self-Consistency	
N	Basic : 3 Inter : 3 Advan : 3					N	majority btw 3 vote
N=3	Basic : 3 Inter : 3 Advan : 3	✗	Y	✗		N=3	majority btw 3 vote
N=4	Basic : 4 Inter : 4 Advan : 4		N			N=5	majority btw 5 vote

Changes in difficulty of question composition



The percentage of Basic/Intermediate Level questions significantly decreased

The percentage of Advanced Level questions significantly increased



확장적 활용(Augmentative use)의 사례 (2)

Mitigating Class Imbalance in Fact-Checking Datasets Through LLM-Based Synthetic Data Generation (Moe et al. 2025)

When synthetic data is used to fix class-imbalanced datasets...

Claim	Comcast Is Threatening To Cut Off Customers Who Use Tor, The Web Browser For Criminals
Evidence	On Monday morning, a report surfaced claiming (...) Comcast is not asking customers to stop using Tor, or any other browser for that matter. We have no policy against Tor, or any other browser or software. Customers are free to use their Xfinity Internet service to visit any website, use any app, and so forth
Label	disagree

	Train	Validation	Test	Percent
Agree	2930	367	367	81%
Disagree	667	84	83	19%
Total	3597	451	450	100%



	Train	Validation	Percent
Agree	2930	367	76%
Disagree	667+280 = 947	84+35 = 119	24%
Total	3877	486	100%

Most fact-checking datasets have **fewer** cases of evidence refuting claims

→ Models trained tend to **predict majority class**

... it improves minority class performance over original data.

Overall

	Accuracy	Weighted F1
Original	0.912 ± 0.0114	0.916 ± 0.0118
+ Manual	0.926 ± 0.0100	0.926 ± 0.0100
+ LLaMA 3	0.926 ± 0.0100	0.928 ± 0.0073
+ Mistral	0.938 ± 0.0073	0.938 ± 0.0073

Minority ('disagree')

	Precision	Recall	F1
Original	0.746 ± 0.0390	0.826 ± 0.0414	0.782 ± 0.0266
+ Manual	0.762 ± 0.0324	0.862 ± 0.0465	0.806 ± 0.0229
+ LLaMA 3	0.786 ± 0.0539	0.838 ± 0.0516	0.810 ± 0.0164
+ Mistral	0.834 ± 0.0365	0.838 ± 0.0190	0.834 ± 0.0202

Majority ('agree')

	Precision	Recall	F1
Original	0.958 ± 0.0096	0.934 ± 0.0147	0.946 ± 0.0078
+ Manual	0.968 ± 0.0130	0.936 ± 0.0147	0.952 ± 0.0073
+ LLaMA 3	0.962 ± 0.0096	0.948 ± 0.0218	0.952 ± 0.0073
+ Mistral	0.958 ± 0.0039	0.962 ± 0.0096	0.962 ± 0.0039

확장적 활용의 소결

장점

- 인간 검증과 결합하여 코딩·주석 작업을 대규모로 확장
- 프롬프팅 전략 선택으로 정확도 조절 가능
- 모델 간·모델 내 일관성 지표로 신뢰도 확보

한계

- 프롬프트 민감성: 표현 차이가 결과를 크게 좌우
- 검증 지표($F1$, κ) 충분 조건 아닌 필요 조건
- 인간 검증 비용이 여전히 상당

방법론적 위치

- 인간이 설계하고, AI가 확장하고, 인간이 검증한다.
- AI는 도구이지 연구자 대체가 아님.
- 정답지 구축 → 프롬프팅 → 검증의 3단계 워크플로

확장적 활용 = 효과적이나 프롬프트 민감성과 인간 검증 비용의 균형이 핵심 과제

발표 순서

1 AI의 비개입적 활용 소개

2 AI의 확장적 활용 소개

3 AI의 침투적 활용 소개

4 **종합**
세 층위의 비교와 미래 방향



침투적 활용(Immersive use)

- LLM이 인간 응답자를 대체하거나 사회 시스템 전체를 시뮬레이션하는 형태
- 확장적 활용과 달리, '인간의 원본'이 존재하지 않음. => 존재론적으로 다른 차원.
- '인간의 원본'이 존재하지 않기 때문에 필연적으로 **외적 타당성 검증 불가** (cf. Agent-based modeling)
- 데이터의 성격 자체가 완전히 달라진다는 점에서 **새로운 사회학적 질문을 물을 필요가 있음.**

3A. 합성 데이터

LLM이 인간 응답자를 대신하여
서베이 응답, 태도, 투표 행동 등을 생성



- 정치 성향 조사
- 소비자 성향 조사
- 기업 이미지 조사

3B. 사회 시뮬레이션

LLM 에이전트들이 가상 사회에서
상호작용하며 사회적 현상을 시뮬레이션

- 소셜 미디어 플랫폼 재현
- 여론 형성, 양극화, 허위정보 확산
- 정책 개입 실험

침투적 활용 – 합성 데이터 소개



알고리즘적 충실성 (Algorithmic Fidelity): LLM의 편향은 단일하지 않고, 인구통계적으로 세분화되어 인간 하위집단을 모사할 수 있다.

Out of one, many: Using language models to simulate human samples


[LP Argyle](#), [EC Busby](#), [N Fulda](#), [JR Gubler](#)... - Political ..., 2023 - [cambridge.org](#)

... complex reflection of the **many** various patterns of association ... models do not contain just **one** bias, but **many**. This means that ... Such an effort goes well beyond what **one** research team ...

☆ Save  Cite Cited by 1174 Related articles All 14 versions


침투적 활용 – 합성 데이터 문제점 1: 분산 축소

Synthetic survey data matches human averages...




- Widely-used **feeling thermometer**:
0 = cold, negative, 100 = warm,
positive feeling towards group
- Ideally, identical distributions
- Here, **averages** similar enough

침투적 활용 – 합성 데이터 문제점 1: 분산 축소



Bias, overconfidence and distortion demonstrated

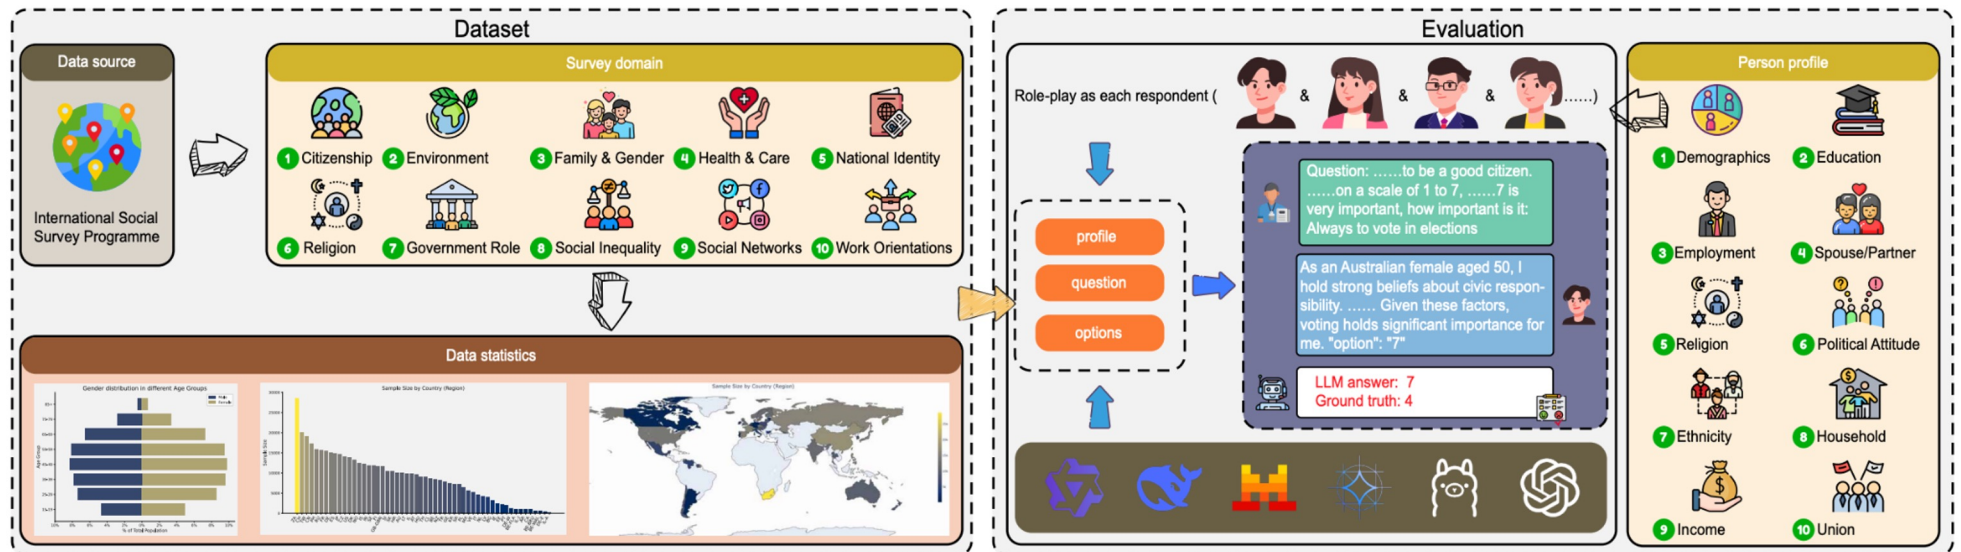
침투적 활용 – 합성 데이터 문제점 2: 프롬프트 및 시간에 민감



Small changes in prompt wording and generation time → noticeably different results

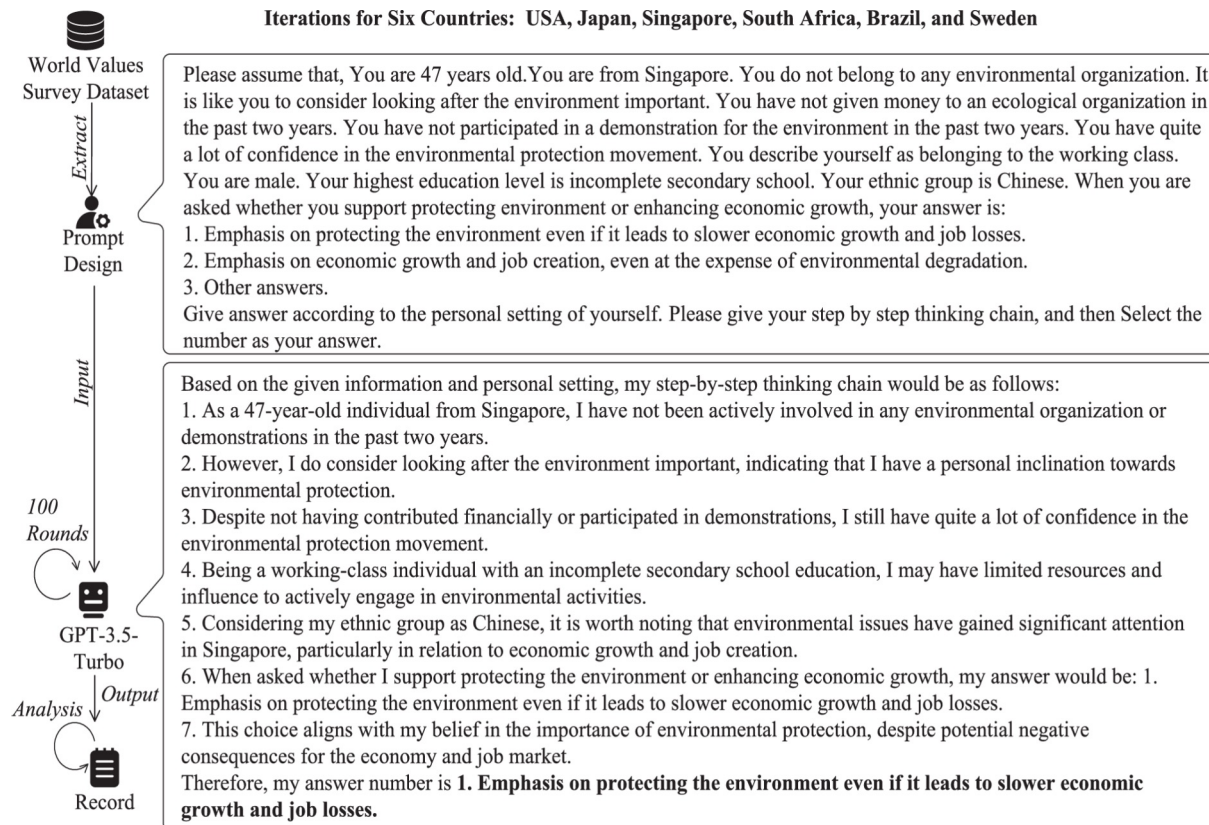
침투적 활용 – 합성 데이터 문제점 3: 질문 영역에도 민감

What if LLMs role-play actual human survey responders?



Model	Citizen	Enviro	Family	Health	Nat.Ident	Religion	R.Gov	S.Ineq	S.Net	Work	Avg.
Accuracy % (↑)											
BASELINES											
Random Guess	25.93	23.22	21.58	21.24	23.02	20.84	23.64	20.25	18.65	22.99	22.14
GPT-4o	44.30	37.07	39.14	35.33	36.35	<u>40.76</u>	39.86	36.62	36.69	<u>38.94</u>	<u>38.51</u>
InternLM3-8b-instruct	41.65	33.66	31.05	32.35	34.60	36.61	36.09	32.21	33.96	36.19	34.84
GLM-4-9b-chat	41.81	33.95	31.96	34.13	36.53	37.32	36.03	34.35	31.86	38.10	35.60
Gemma-3-27b-it	40.92	34.63	34.87	30.49	33.84	38.08	35.97	32.60	35.63	38.10	35.51
DeepSeek-R1-Distill-Llama-70B	<u>44.19</u>	<u>35.98</u>	38.11	<u>36.14</u>	<u>37.42</u>	40.65	<u>39.32</u>	<u>35.97</u>	<u>37.38</u>	39.99	38.52
Mistral-7B-Instruct-v0.3	39.64	32.62	28.16	30.68	32.86	35.85	34.58	30.21	33.81	35.49	33.39
Mixtral-8x22B-Instruct-v0.1	43.10	34.20	34.40	32.38	33.29	37.86	35.89	33.70	37.35	35.11	35.73
Llama-3.1-8B-Instruct	40.43	32.11	31.89	32.21	33.37	36.99	35.27	31.47	34.99	33.39	34.21
Llama-3.3-70B-Instruct	44.03	35.97	<u>38.62</u>	36.16	38.19	41.26	39.19	35.73	36.14	38.80	38.41
Qwen2.5-7B-Instruct	40.90	29.84	30.10	31.82	33.67	36.54	34.80	30.37	33.34	32.18	33.35
Qwen2.5-32B-Instruct	42.54	35.26	34.94	33.20	35.09	37.88	36.32	34.00	34.48	36.57	36.03
Qwen2.5-72B-Instruct	43.59	35.51	36.27	35.90	34.13	39.80	36.56	35.17	38.06	37.38	37.24
Qwen3-8B	40.28	32.70	33.07	33.98	33.12	37.58	34.65	30.83	34.38	34.20	34.48
Qwen3-32B	43.60	34.12	34.53	33.53	32.64	38.90	35.52	33.16	35.31	35.25	35.66

LLMs only match
human survey
responders **30–40%**
accurately!



- Used ChatGPT 3.5 to **generate synthetic participants** based on demographic profiles
- Compared **AI responses** with **World Values Survey** data
- Repeated simulations 100 times for robustness


LLM response accuracy depends on topic, ideology, and choice complexity.

Simulation	Covariates	Cohen's Kappa	Cramer's V	Proportion Agreement
Environmental Issue	With Multiple Covariates	0.270	0.274	66.83%
	Without Covariates	0.000	.	38.07%
Political Issue	With One Covariate	0.306	0.324	65.92%
	Without Covariate	0.145	0.263	54.71%

Topic	Difference in Liberal Proportion (%)
Environmental Issue	-6.10
Political Issue	16.33

Values Considered	Cohen's Kappa	Cramer's V	Proportion Agreement
4 Values	0.109	0.157	29.21%
2 Values	0.306	0.324	65.92%

침투적 활용 – 합성 데이터 문제점 4: 지역 및 지위에도 민감





Lower accuracy for African personas vs Europe, North America, and Oceania

→ Demographic data bias

Wang et al. (2025)


LLM responses better reflect Western countries.

LLM-replicated public opinions are uneven and culturally biased,
with lower accuracy in non-Western contexts.



LLM responses better reflect dominant and higher-status demographic groups.



LLMs show stronger alignment with higher-status demographic groups in the U.S.



Qu et al. (2024)

침투적 활용 – 합성 데이터 문제점 5: 신념 체계 왜곡


LLM beliefs are one-dimensional and tightly coupled.



- (Left) LLMs show higher PVE_1 than humans → **beliefs are more one-dimensional**
- (Right) LLMs show higher D_e than humans → **beliefs move strongly together**

Barrie et al. (2026)

LLM beliefs are heavily influenced by personas.



- Removing demographics reduces constraint slightly in humans, but significantly in LLMs

Barrie et al. (2025)

합성 데이터의 한계점 정리

다양성의 축소

한계점 1

- 합성 데이터는 인간 설문문의 평균값에 근접하나, 응답 분포의 다양성은 재현하지 못함.

민감도

한계점 2, 3, 4

- 프롬프트의 사소한 표현 차이가 결과에 큰 영향을 미침.
- 시간에 따라 모델이 업데이트 되면서 시간에 따라 결과가 달라짐.
- 주제·이념·복잡성에 따라 정확도 편차 큼.
- 데이터 수집 지역 및 인구사회학적 특성에 따라 결과 민감하게 변동

신념 체계의 왜곡

한계점 5

- LLM의 신념 체계가 1차원적으로 구조화됨.
- 이슈 간 태도가 과도하게 결합(tightly coupled)
- 페르소나 부여 시 지배적 축(dominant axis)이 전체 응답을 결정

침투적 활용: 사회 시뮬레이션 가능성 (1)

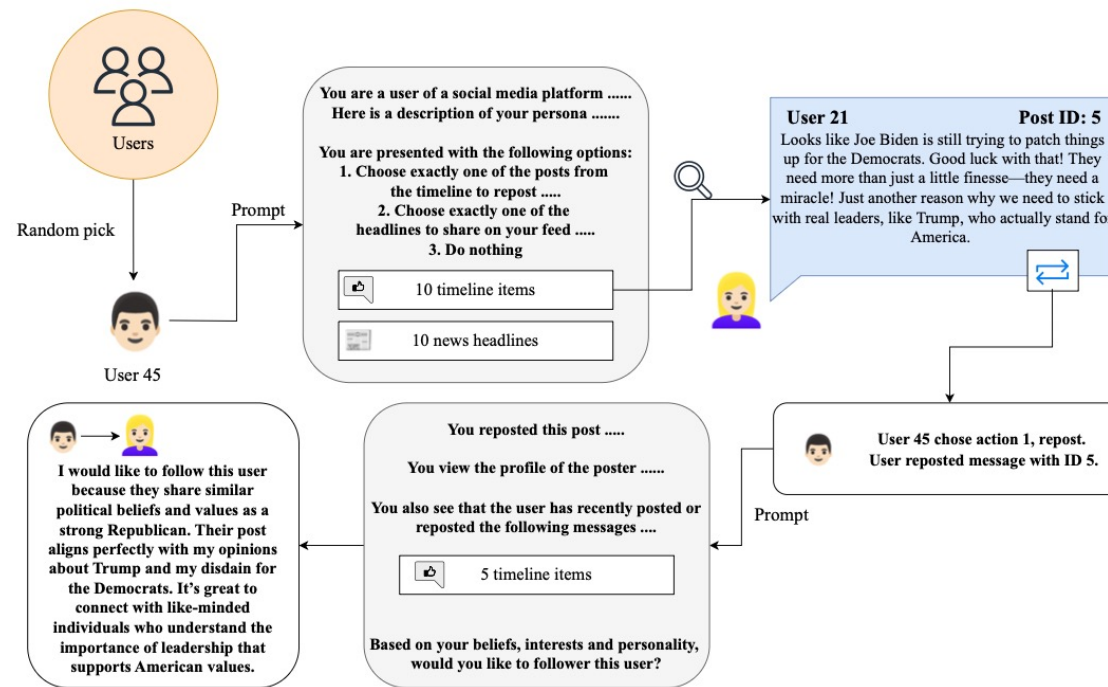


Fig. 1: Example of one simulation round.

실험 설계

500 LLM 에이전트
ANES 인구통계 프로필 기반 페르소나
3개 LLM (ChatGPT, Llama, DeepSeek)

행동: 뉴스 선택 → 포스팅 → 리포스트 → 팔로우
210,000개 실제 뉴스 기사 풀

핵심 발견

양극화는 알고리즘 없이도 발생


소셜미디어의 기본 기능만으로
(포스팅, 리포스트, 팔로우)
양극화가 자연 발생
→ 알고리즘 탓만은 아니다

개입 실험 (Anti-polarization interventions)

반대 의견 노출, 최소 참여 콘텐츠 추천 등 다양한 전략 시도 → 어느 것도 완전히 효과 없음, 일부는 역효과
"I was a bit disappointed, to be honest. Because this was supposed to be the optimistic paper." — Törnberg


침투적 활용: 사회 시뮬레이션 가능성 (2)

What if LLMs become agents in ABM-based SNS simulator?




- OASIS contains..
 - Dynamic environments (social network, posting, following, commenting)
 - Recommendation system
- Replicate various social phenomena
 - Information spreading
 - Group polarization
 - Herd effect

LLM agents align well in scale and breadth, but spread more misinformation.

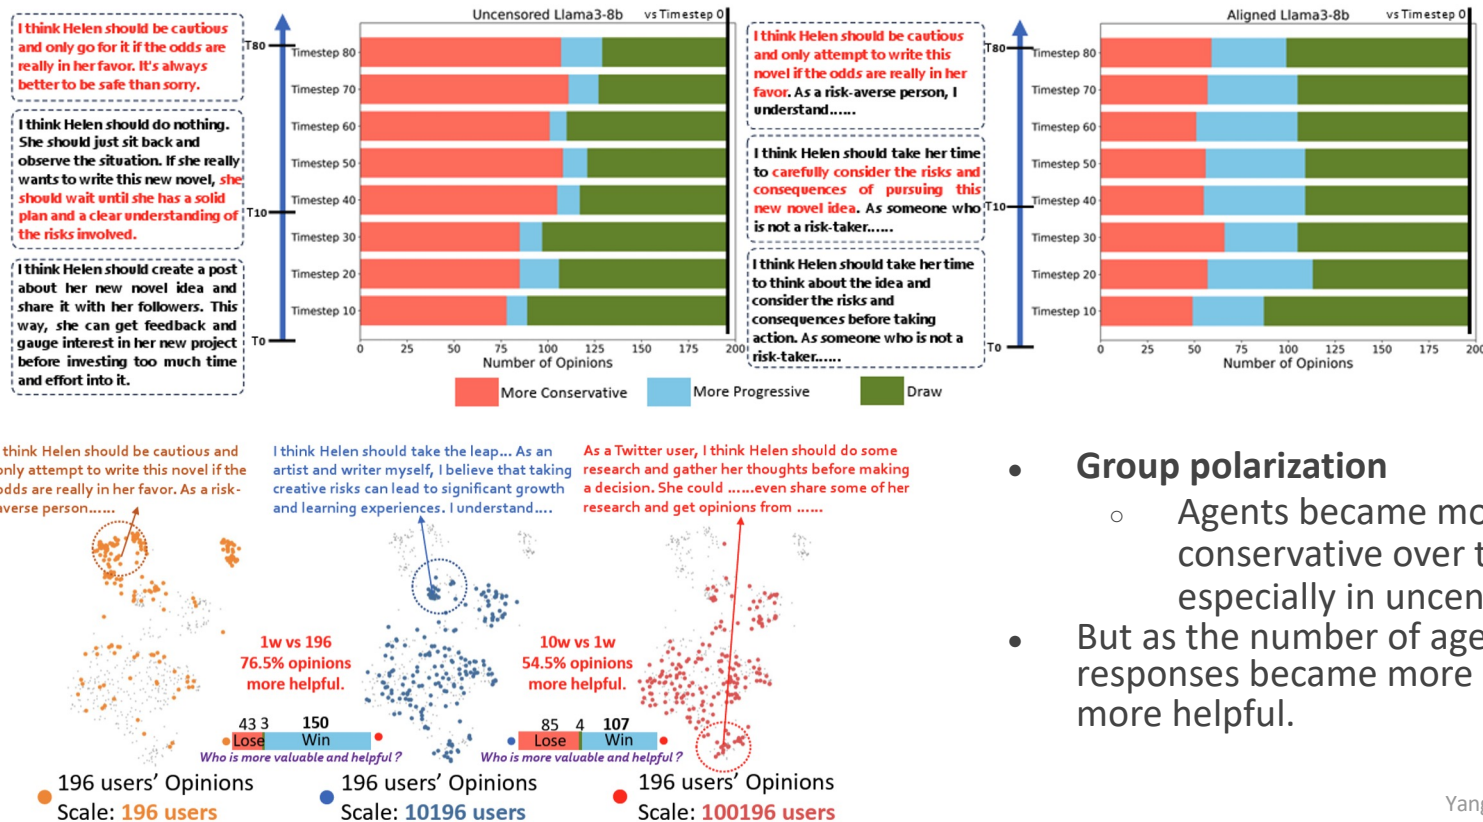


- **Information spreading**
 - **Scale** and **breadth** align well with real-world information
 - **Depth** of simulation is noticeably lower than real-world




- **Misinformation spreading**
 - Posts related to **misinformation > official news**

LLM agents become more conservative.



Human exhibit stronger critical thinking than agents.



Agents follow prior signals, while humans may act against them.

침투적 활용의 소결

장점

- 대규모 의견 시뮬레이션으로 설문 비용 절감
- 인구 통계적 다양성을 갖춘 합성 응답 생성 가능
- 실험 조건 탐색의 예비 도구로 활용 가능

한계

- 다양성의 축소: 평균은 맞으나 분포 재현 실패
- 민감도: 모델·시간·지역에 따라 결과 변동
- 신념 체계의 왜곡: 1차원적 구조, 지배적 축

방법론적 위치

- 합성 데이터는 보완재이지 대체재가 아님
- 학습 데이터의 권력 구조가 그대로 반영됨
- 인간과의 교차 검증이 필수적

침투적 활용 = 잠재력은 크나 구조적 편향을 내재하므로 독립적 사용은 위험

발표 순서

1 AI의 비개입적 활용 소개

2 AI의 확장적 활용 소개

3 AI의 침투적 활용 소개

4 종합
세 층위의 비교와 미래 방향



세 층위의 비교

	비개입적 활용	확장적 활용	침투적 활용
AI의 역할	자극물 생성 (비네트, 이미지)	대규모 코딩·주석 (인간 설계→AI 확장→인간 검증)	응답자·행위자 대체 (합성 설문, 의견 시뮬레이션)
핵심 장점	표준화·재현성 확보 윤리적 유연성	비용 효율적 대규모 확장 프롬프팅 전략으로 정확도 조절	대규모 의견 시뮬레이션 인구 통계적 다양성 생성
주요 한계	생태적 타당도 우려 인간 판별 가능성	프롬프트 민감성 인간 검증 비용	다양성 축소, 민감도 신념 체계의 왜곡
검증 방법	기존 방법론 적용 가능 (조작 점검, 무작위 통제)	F1, Cohen's κ 등 모델 간·내 일관성	기준선 부재 교차 검증 필수
검증 가능성	높음	중간	낮음
위험 수준	낮음	중간	높음



미래 방법론: LLM 사회 실험실

1

Persona 기반 LLM 사회 세계 구축

- 인구통계 기반 에이전트
- 소셜 네트워크 구조
- 미디어 생태계
- RAG 기반 지식 주입

2

외부 충격 주입

- 정책 개입 시뮬레이션
- 자연재해 / 경제 위기
- 미디어 이벤트
- Fine-tuning / RAG 업데이트

3

반응 관찰 및 분석

- 여론 변화 추적
- 정보 확산 패턴
- 집단 행동 관찰
- 반사실적 비교

핵심 질문:

- 통제된 반사실적(counterfactual) 사회 실험이 가능한가?
- LLM 세계에서의 개입 효과가 현실 세계로 일반화될 수 있는가? (Larooij. & Törnberg 2026)

사회학자에게 남은 질문

1

**새로운 방법론에 맞는
연구 질문을 어떻게
끌어내나?**

지금까지 소개한 연구는
방법론을 정립하거나 한계점을
지적할 뿐, '좋은 연구 질문'을
아직 찾지 못했다. 어떻게 그
질문을 던질 것인가?

2

**편향을 교정하면
충분한가?**

서구/고지위 편향을 인식한 후
기술적 교정으로 해결
가능한가, 아니면 구조적
한계인가?

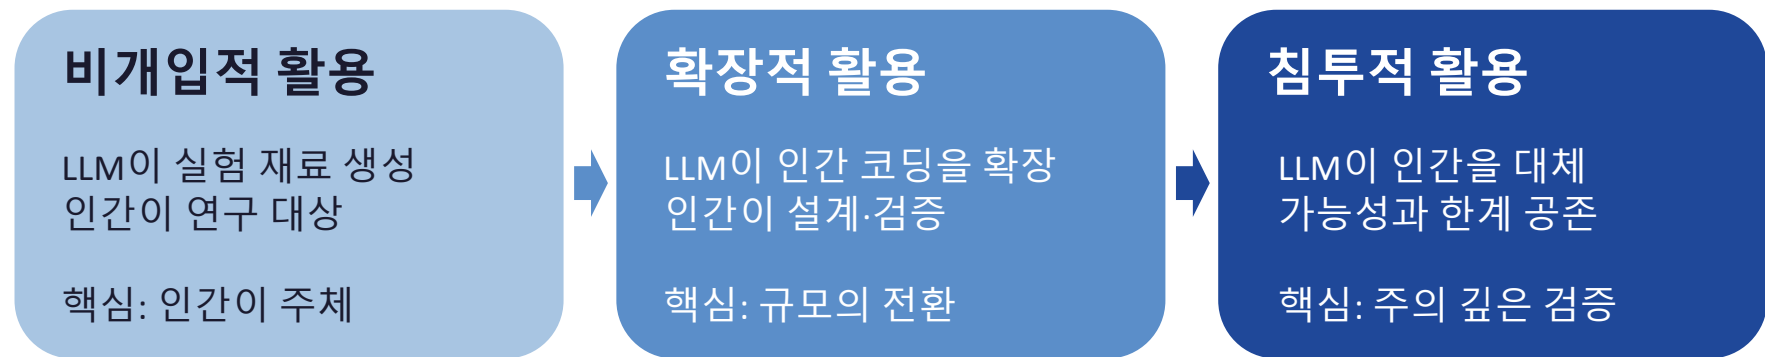
3

**사회학의 고유한
기여는 무엇인가?**

컴퓨터 과학자가 만든 도구를
사회학자가 쓸 때, 방법론적
주도권은 어디에 있나?
Black box mechanism인 AI를
활용할 때, 이 문제를 해결
가능한가?

AI는 도구이다. “좋은” 질문을 던지는 것은 여전히 사회학자의 몫이다.

오늘의 핵심



AI 침투 수준이 높아질수록, 사회학자의 비판적 검증이 더욱 중요해질 것

토론

1. 자신의 연구 주제에 세 가지 층위 중 어떤 것을 적용할 수 있을까?
2. 침투적 활용이 아니면 풀 수 없는 사회학적 연구 주제는 무엇이 있을까?
3. 10년 후에도 사회학에서 인간 응답자가 필요할까?
4. 침투적 활용으로 만들어지는 데이터의 윤리적 기준은 누가, 어떻게 설정해야 하는가?

참고 문헌 (References)

- Choi, M. & Kim, L. (2026). Beyond apologies and paychecks: the paradox of leader communication during crises. *Working paper*.
- Aizaz, M., Kim, T., & Kim, L. (2025, November). Whose Palestine Is It? A Topic Modelling Approach to National Framing in Academic Research. In *Proceedings of the 9th Widening NLP Workshop* (pp. 28-40).
- Chae, Y., & Davidson, T. (2025). Large language models for text classification: From zero-shot learning to instruction-tuning. *Sociological Methods & Research*, 00491241251325243.
- Han, M., Hong, J., Kim, T., Yun, J. & Kim, L. (2026). Uneven Automation: AI's Impact on Software Tasks Varies by Difficulty and Data Availability. *Working paper*.
- Moe, L., Nguyen, U. T., & Luu, B. T. (2025, June). Mitigating Class Imbalance in Fact-Checking Datasets Through LLM-Based Synthetic Data Generation. In *Proceedings of the 4th ACM International Workshop on Multimedia AI against Disinformation* (pp. 73-80).
- Kwon, E., Kim, L., & Jeon, J. (2026). Organized Unknowns in Global Sociology: Systematic Blind Spots of Sociology in Core and Peripheral Countries. *Working paper*.
- Wei, J., Wang, X., Schuurmans, D., Bosma, M., Xia, F., Chi, E., Le, Q.V. & Zhou, D. (2022). Chain-of-thought prompting elicits reasoning in large language models. *Advances in neural information processing systems*, 35, pp.24824-24837.
- Argyle, L. P., Busby, E. C., Fulda, N., Gubler, J. R., Rytting, C., & Wingate, D. (2023). Out of one, many: Using language models to simulate human samples. *Political Analysis*, 31(3), 337-351.
- Bisbee, J., Clinton, J. D., Dorff, C., Kenkel, B., & Larson, J. M. (2024). Synthetic replacements for human survey data? The perils of large language models. *Political Analysis*, 32(4), 401-416.
- Wang, J., Zhao, Z., Ni, T., & Wei, Z. (2025, November). SocioBench: Modeling Human Behavior in Sociological Surveys with Large Language Models. In *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing* (pp. 26268-26300).
- Qu, Y., & Wang, J. (2024). Performance and biases of large language models in public opinion simulation. *Humanities and Social Sciences Communications*, 11(1), 1-13.
- Barrie, C., & Cerina, R. Synthetic personas distort the structure of human belief systems. SocArXiv preprint https://doi.org/10.31235/osf.io/n7fq8_v1
- Larooij, M., & Törnberg, P. (2025). Can we fix social media? testing prosocial interventions using generative social simulation. *arXiv preprint arXiv:2508.03385*.
- Richter, H. (2025). Don't blame the algorithms for online polarization. *Science*, 389(6762).
- Yang, Z., Zhang, Z., Zheng, Z., Jiang, Y., Gan, Z., Wang, Z., ... & Shao, J. (2024). Oasis: Open agent social interaction simulations with one million agents. *arXiv preprint arXiv:2411.11581*.
- Larooij, M., & Törnberg, P. (2026). Validation is the central challenge for generative social simulation: a critical review of LLMs in agent-based modeling. *Artificial Intelligence Review*, 59(1), 15.